





Capítulo 1: Fundamentos del Big Data

Parte I: Del problema
al paradigma

Dr. Julio López-Nunez (2026)

Objetivos de Aprendizaje y Pregunta Guía




El Dilema Arquitectónico

¿Por qué las tecnologías tradicionales para gestionar datos dejaron de ser suficientes, forzando la creación de un nuevo paradigma?

✗	El Error Frecuente: Big Data consiste únicamente en almacenar grandes cantidades de información.
✓	La Realidad: El verdadero desafío radica en la incapacidad física y económica de los sistemas tradicionales para procesar el caos digital.

Motivación inicial: El límite tecnológico



CASO BREVE: Cadena de Supermercados


El Escenario: Millones de transacciones diarias integradas con rastros digitales de clientes (hábitos, horarios, preferencias).

El Problema: Bases de datos relacionales colapsando bajo el volumen sostenido. Tiempos de procesamiento inaceptables para reportes estratégicos.

Reflexión:


¿Qué características de este escenario permiten anticipar que una arquitectura tradicional dejará de ser suficiente?

1.2 La explosión de los datos



1.3 El problema: las limitaciones de las tecnologías tradicionales


Escalabilidad Vertical - Scale-up



LIMITACIONES:

- **Rendimiento:** Tiempos de respuesta degradados ante concurrencia masiva.
- **Costos Crecientes:** Hardware empresarial con retornos decrecientes.
- **Disponibilidad:** Dependencia de un único equipo; si falla, cae el servicio.

El Nuevo Paradigma



ERROR FRECUENTE: "Las bases de datos relacionales ya no sirven". **FALSO.** Siguen siendo la mejor solución para aplicaciones transaccionales estándar. Fallan solo cuando volumen/velocidad superan su diseño original.


1.4 El nacimiento del paradigma Big Data




El Cambio de Paradigma: Procesamiento Distribuido

A principios de los 2000, empresas como Google enfrentaron un volumen imposible de procesar. La solución no fue construir una supercomputadora, sino conectar miles de computadoras convencionales.

El Pasado: Escalabilidad Vertical



La Revolución: Escalabilidad Horizontal




1 **2003/2004:** Google publica los artículos científicos de Google File System y MapReduce.

2 **2005:** Nace **Hadoop** (inspirado en Google), democratizando el procesamiento y almacenamiento distribuido mediante software libre.

1.5 ¿Qué es Big Data? (La evolución del concepto)

DEFINICIÓN OPERATIVA:

Paradigma tecnológico y organizacional que integra arquitecturas, métodos y herramientas para **capturar, almacenar, procesar y analizar grandes volúmenes de datos**... para transformarlos en información útil.




ERROR FRECUENTE:



'Big Data es solo almacenar muchos datos'. **FALSO**. El valor no está en acumular, sino en la capacidad analítica y la infraestructura que lo soporta.

1.6 Las características del Big Data (El modelo de las 5V)

Caso de Referencia: Plataforma de Streaming de Video




1.7 Tipos de datos

Estructurados	Semiestructurados	No estructurados
		
Esquema fijo (filas/columnas). Altísima facilidad de consulta mediante SQL. Tecnología habitual: BD Relacionales (Ej: Matrícula, Facturas).	Esquema flexible/jerárquico. Facilidad media de consulta. Tecnología habitual: Bases NoSQL documentales (Ej: JSON, XML, APIs).	Sin esquema fijo. Altísima complejidad de análisis. Representa >80% de los datos actuales (Ej: Video, Imágenes, Texto, Sensores).

CONCEPTO CLAVE: El tipo de dato determina directamente la arquitectura tecnológica requerida para su almacenamiento y procesamiento.

Resumen Parcial e Introducción al Ecosistema



✓ CHECKPOINT:

Hasta ahora hemos visto:

- La crisis del 'Scale-up'
- El nacimiento de Hadoop
- La definición y las 5V
- La diversidad de datos.

EL MITO DE LA SUSTITUCIÓN:

Big Data no reemplaza a los sistemas relacionales ni al Business Intelligence.

Actúa como el habilitador de infraestructura cuando estos últimos enfrentan límites de escala, preparando el terreno para modelos predictivos (ML/IA).

1.8 Comparativa del Ecosistema de Datos

Tecnología	Objetivo Principal	¿Qué pregunta responde?	Ejemplo Práctico
Base de Datos Relacional	Registrar operaciones	¿Qué ocurrió?	Sistema académico
Data Warehouse	Integrar información histórica	¿Qué ha ocurrido en el tiempo?	Históricos de ventas
Business Intelligence	Analizar y visualizar	¿Qué está pasando?	Dashboards
Big Data	Procesar grandes volúmenes multiformato	¿Cómo gestiono estos datos distribuidos?	Sensores IoT masivos
Data Science / ML	Descubrir patrones / Aprender automáticamente	¿Qué ocurrirá?	Predicción de abandono
Inteligencia Artificial	Automatizar capacidades cognitivas	¿Cómo puede actuar el sistema?	Asistentes generativos

1.9 ¿Cuándo una organización realmente necesita Big Data?



CONCEPTO CLAVE: Big Data no debe seleccionarse por moda tecnológica, sino porque constituye la única solución viable (costo-beneficio) para un problema de escala.

El Diagnóstico en la Práctica

✗ No Requiere Big Data

Sistema Universitario

Contexto: Gestión académica de 25,000 estudiantes.

Por qué no: Datos 100% estructurados (matrículas, notas, horarios). Volumen manejable.

Solución: Base de datos relacional (SQL Server/PostgreSQL). Big Data solo agregaría costos y complejidad innecesaria.



✓ Sí Requiere Big Data

E-commerce Global

Contexto: Cientos de millones de transacciones, clics y búsquedas diarias a nivel mundial.

Por qué sí: Alta velocidad, variedad (datos de navegación web, inventario, perfiles), y necesidad de recomendaciones en tiempo real.

Solución: Arquitectura distribuida para escalabilidad.



Radiografía de los Datos Urbanos

GPS de Buses

Datos Semiestructurados | Alta Velocidad (reporte por segundo).

Cámaras CCTV

Datos No Estructurados | Alto Volumen (transmisión continua de video).

Catastro Municipal

Datos Estructurados | Alta Veracidad (registros legales en SQL).

Redes Sociales


Datos No Estructurados | Alta Variedad (denuncias ciudadanas en texto, imagen y video).



Conclusión: Ninguna base de datos relacional tradicional puede unificar este ecosistema simultáneamente.

La Arquitectura de la Solución

Integración tecnológica para decisiones inteligentes.



1. Captura Masiva

Ingesta de datos de sensores, cámaras y SQL heredado.

2. Almacenamiento Distribuido


El sistema elimina el Punto Único de Falla.
Si un nodo cae, la ciudad no pierde sus datos.

3. Procesamiento (El Valor)

Transformación de datos crudos en conocimiento para el gobierno urbano.

Impacto: El Big Data habilita a la inteligencia artificial (Machine Learning) para predecir atascos de tráfico y optimizar el consumo eléctrico de la ciudad en tiempo real.

Del Caos al Conocimiento



El paradigma del Big Data no nació simplemente porque tuviéramos más información.
Nació porque la arquitectura tradicional se rompió bajo el peso de la transformación digital.

El verdadero poder del Big Data no radica en el tamaño de los datos que almacenamos, sino en la capacidad de la arquitectura distribuida para transformarlos en decisiones exactas, oportunas y valiosas.

Actividad Grupal & Resumen del Capítulo

ACTIVIDAD: EQUIPO CONSULTOR (5 min)

Diagnóstico del caso Nova Ciudad.

-  **Identificar tipos de datos** por fuente.
-  **Mapear las dimensiones 5V** presentes.
-  **Redactar informe ejecutivo** justificando técnicamente por qué una arquitectura tradicional fallaría aquí.

IDEAS PRINCIPALES (RESUMEN)

-  **Big Data** nace por **limitaciones físicas** del 'scale-up' (escalabilidad vertical).
-  Se define por su **complejidad técnica** (5V) y la **generación de valor**, no solo por el tamaño.
-  Es un **complemento** para **BI e IA**, requiriendo un análisis **estricto de costo-beneficio** antes de su implementación.

Referencias y Próximos Pasos

LECTURAS OBLIGATORIAS:

- O'Neil, C. (2017). Weapons of Math Destruction (Caps 1-2).
- López Núñez & Cerda-Neumann. (2022). Expectations over Big Data.



RESPUESTA A LA PREGUNTA GUÍA:

Las arquitecturas tradicionales fracasaron porque el crecimiento exponencial, la velocidad y la diversidad de datos superaron los límites físicos y económicos del servidor único, haciendo indispensable el procesamiento distribuido.

EL DESAFÍO DEL CAPÍTULO 2: Ya comprendemos el por qué y el cuándo. El próximo capítulo responde al CÓMO: El diseño técnico de arquitecturas y procesamiento distribuido (Hadoop y Spark).