



Capítulo 2: Hadoop: Visión Global y Arquitectura



Pregunta Guía:

¿Cómo permite Hadoop almacenar y procesar grandes volúmenes de datos mediante una arquitectura distribuida y cuáles son los componentes que hacen posible su funcionamiento?

Objetivos de Aprendizaje



Comprender el propósito de Apache Hadoop frente a los desafíos de los datos masivos.

Explicar el origen de Hadoop a partir de las investigaciones de Google.


Identificar los cuatro componentes principales de la arquitectura base de Hadoop.

Reconocer las herramientas especializadas que conforman el ecosistema ampliado.

Comprender la arquitectura local del laboratorio basado en contenedores Docker.

El Desafío Big Data y la Solución Distribuida


El Límite Tradicional



Bases de datos tradicionales

- Excelente para aplicaciones estándar
- Límite de capacidad computacional centralizada
- Genera cuellos de botella ante escala masiva

El Paradigma Distribuido



Apache Hadoop (Framework Open Source)

- Almacenamiento y procesamiento distribuido
- Alta escalabilidad y tolerancia a fallos
- Menor costo utilizando hardware convencional

El Origen de Hadoop: De Google al Software Libre




Hoy: Un referente fundamental para comprender los principios de las arquitecturas Big Data modernas.

¿Qué es Apache Hadoop?

Un framework de código abierto diseñado para almacenar y procesar grandes volúmenes de datos distribuyendo las tareas a través de un clúster.

Hardware Convencional:
No requiere servidores de alto costo. Utiliza equipos estándar interconectados.



Escalabilidad Horizontal:
Ampliación simple de la capacidad añadiendo nuevos nodos al clúster.

Tolerancia a Fallos:
Redundancia natural mediante la arquitectura distribuida. Sobrevive a caídas de hardware.

Arquitectura Base: Los 4 Módulos de Hadoop



Hadoop Common


Bibliotecas, herramientas y servicios básicos compartidos necesarios para todo el ecosistema.



HDFS

(Hadoop Distributed File System)

Almacenamiento. Garantiza disponibilidad y tolerancia a fallos mediante replicación de datos en los nodos.



YARN

(Yet Another Resource Negotiator)


Administración. Asigna recursos (memoria y CPU) y coordina la ejecución de las aplicaciones en el clúster.



MapReduce

Procesamiento. Divide el trabajo en múltiples procesos que se ejecutan simultáneamente.

El Ecosistema Ampliado de Hadoop




Matriz Diagnóstica del Ecosistema

Tecnología	Capa de Arquitectura	Función Principal
HDFS	Almacenamiento	Sistema de archivos distribuido en nodos del clúster.
Hive	Consulta	Acceso a datos mediante lenguaje similar a SQL (HiveQL).
Spark	Procesamiento	Motor distribuido para análisis masivo rápido en memoria.
Kafka	Ingesta / Tiempo Real	Transmisión de datos mediante intercambio de mensajes.
NiFi	Integración	Automatización, enrutamiento y diseño de flujos de información.
Hue	Administración Web	Interfaz visual centralizada para gestionar el clúster.
Zeppelin	Análisis Interactivo	Entorno basado en notebooks para visualización y código.

Punto de Control y Reflexión

La adopción de tecnologías Big Data no depende únicamente del volumen de datos, sino también de la velocidad, variedad y necesidades analíticas de una organización.

- > ¿Estás de acuerdo con esta afirmación? ¿Por qué?



- > En sus propias palabras, expliquen la relación que existe entre HDFS, YARN y MapReduce dentro de la ejecución de una tarea en el clúster.

El Laboratorio del Curso: Infraestructura Local



Contenedores (Docker Compose)

Todo el ecosistema Hadoop integrado y estandarizado en contenedores locales, sin configuraciones nativas complejas.



Repositorio GitHub

Código fuente, guías paso a paso, datasets y configuración base en:
github.com/juliopez/Hadoop




Soporte Audiovisual

Lista de reproducción oficial para demostraciones de instalación y resolución de problemas.



Caso de Estudio: Arquitectura SmartCity Analytics



Actividad Práctica: Laboratorio 2.1

Objetivo: Familiarizarse con el entorno Docker, identificar componentes y verificar la infraestructura base del laboratorio.

[Paso_1] Acceder al repositorio oficial en GitHub e identificar la estructura de carpetas (archivos .yaml, documentación).

[Paso_2] Completar la tabla de componentes (Actividad 2), identificando el rol que juega cada tecnología en el entorno Docker.

[Paso_3] Explorar la lista de reproducción oficial para ubicar los videos de instalación inicial.

Evidencias Esperadas:

- ☐ Capturas de acceso a GitHub y YouTube
- ☐ Tabla de componentes completa
- ☐ Respuestas al cuestionario de análisis

Debate: Aplicación a SmartCity Analytics

01. Fuentes

Identifique 5 posibles fuentes de datos en una ciudad inteligente y determine qué tipo exacto de información generan.

02. Justificación


¿Por qué resulta imperativo utilizar una plataforma Big Data (Hadoop) para almacenar esta información en lugar de una base de datos relacional central?

03. Riesgos (SP0F)

¿Qué desafíos críticos o catástrofes operativas podrían presentarse si toda la información de la ciudad se almacenara en un único servidor?

Preparar respuestas para discusión en plenaria.

Resumen del Capítulo



Referencias y Lecturas Recomendadas

[Bibliografía Básica y Oficial]

- White, T. (2015). Hadoop: The Definitive Guide (4th ed.). O'Reilly Media.
- Minelli, M., et al. (2013). Big Data, Big Analytics. Wiley.
- Documentación oficial: hadoop.apache.org

[Fundamentos e Investigación]

- Dean, J., & Ghemawat, S. (2004). MapReduce: Simplified Data Processing on Large Clusters. OSDI.
- Ghemawat, S., et al. (2003). The Google File System. SOSP.
- Shvachko, K., et al. (2010). The Hadoop Distributed File System. IEEE.

Repositorio oficial del curso: github.com/juliopez/Hadoop