


Infraestructura Big Data en 20 Minutos

Del aprovisionamiento en AWS a un ecosistema Dockerizado funcional (Hadoop, Spark, NiFi & Kafka).

```
>_ aws provision --stack big_data  
--config docker-compose.yml
```



Un playbook técnico secuencial.

Entorno de Trabajo: AWS Educate



Vista Profesor


- Creación de salas de trabajo y asignación de presupuesto (ej. \$50 USD).
- Inscripción por lotes mediante plantilla Excel (solo requiere correo electrónico).



Vista Alumno

- Panel de control de sesión con límite de tiempo (ej. 3 horas / 180 min).
- Acceso directo a la consola de administración de AWS para lanzar instancias EC2.

Fase 1: Aprovechamiento EC2



System Dashboard

S0: **Ubuntu Server 2020**

Procesamiento: **4 vCPUs**
(Necesario para orquestación múltiple)


Memoria: **16 GB RAM**

Almacenamiento: **60 GB Disco**
(Incrementado desde los 8 GB por defecto)

Etiqueta: **servidor hadoop**

Nota de Red: El entorno de AWS proporciona una velocidad de descarga de paquetes drásticamente superior a las redes locales, optimizando la instalación.

Matriz de Seguridad y Reglas de Red



Habilitar todos los puertos TCP permite la conexión directa a las interfaces gráficas de los múltiples servicios de Big Data desde nuestro navegador local.

Fase 2: Conexión Inicial y Autenticación

Paso 1: Localización y Permisos

Contexto: Abrir terminal en la carpeta de descargas locales.

```
chmod 400 server.pem
```

(Ajuste de privilegios de lectura)



Paso 2: Inyección SSH

```
ssh -i server.pem ubuntu@[DIRECCION_IP_AWS]
```

Resultado: Acceso a la interfaz de línea de comandos de la máquina remota Ubuntu.

Transición de Acceso: Abandonando el Archivo .PEM

Diagnóstico de Métodos de Acceso

Método	Dependencia	Riesgo/Ventaja
Archivo .pem	Archivo físico local	Pérdida total de acceso si se extravía.
Usuario Root	Contraseña universal	Acceso ágil desde cualquier dispositivo (ssh root@[IP]).

Modificación del Kernel con vi

- ☐ Crear contraseña: `passwd root` -> Cambiar usuario: `su root`
- ☐ Editar: `vi /etc/ssh/sshd_config`
- ☐ Habilitar: Descomentar `PermitRootLogin yes` y cambiar a `PasswordAuthentication yes`
- ☐ Guardar/Salir: Modo Insert -> `Esc` -> `:wq`
- ☐ Reiniciar servicio: `service ssh restart`

Fase 3: Acondicionamiento del Entorno Base

Actualización

Certificados

Motor Docker

Control de
Versiones



**apt update &
apt upgrade**

(Actualización de
repositorios
nativos)

Registro de
certificados de
seguridad
necesarios para
las descargas de
Docker.

Descarga e
instalación de
paquetes
principales de
Docker.

apt install git

Verificación de
sistema con **git**
--version
(ej. v2.25).


El Paradigma Docker: Agilidad Estructural

VirtualBox / VMware



(Requiere instalar un sistema operativo completo por cada servicio).

Docker



Docker no emula máquinas completas; actúa como una nueva distribución de Linux enfocada en **Big Data**, compartiendo una base mínima (el **Kernel**) para desplegar contenedores simultáneos con fricción cero.

Instalación y Orquestación de Contenedores



Paso 1: Clonación

`git clone [URL_REPOSITORIO]`

(Descarga la infraestructura preconfigurada en el directorio **hadoop**).



15 Minutos


Paso 2: Despliegue

`cd hadoop -> docker-compose up -d`

Contexto Operativo: Es necesario habilitar el servicio y otorgar privilegios a **docker-compose** previamente. Este comando único activa la descarga, extracción y configuración paralela de todos los servicios. Tiempo estimado: ~15 minutos.

El Ecosistema Desplegado: Arquitectura de Servicios

```
docker-compose up -d
```



Mapa de Control: Acceso a Interfaces Gráficas

Navegar a `[IP_PÚBLICA_AWS]:[PUERTO]` en el navegador local.

Servicio	Puerto	Función
Hadoop HDFS	50070	Sistema de archivos distribuido.
Spark Master / Worker	8080 / 8081	Monitor de clúster de procesamiento.
Hue	8888	Puede requerir reinicio del contenedor la primera vez.
NiFi	9090	Diseño de pipelines visuales.
Kafka UI	3030	Ver Tópicos, Productores y Consumidores.
StreamSets	18630	Credenciales por defecto: admin/admin.

Interacción Interna: Acceso a Servicios vía CLI

Hive (Consultas SQL)

1. Entrar al contenedor:

```
docker exec -it  
[nombre_contenedor_hive] bash
```

2. Ejecutar el prompt de la base de datos:

```
cd /opt/hive/bin -> ./hive
```

Spark / Scala (Programación)

1. Entrar al contenedor:

```
docker exec -it  
[nombre_contenedor_spark] bash
```

2. Inicia el entorno de programación en Scala para procesamiento en memoria:

```
cd spark/bin -> ./spark-shell
```


Un Pipeline de Datos Real



Origen:
API de Twitter

Captura de
información en línea.



Ingesta:
Apache NiFi

Orquesta la captura
y enruta el flujo de
datos.



Streaming:
Apache Kafka

Almacena
temporalmente los
datos como un
Productor/Consumidor
de alta velocidad.



Procesamiento:
Apache Spark / Scala

Consume los datos
de Kafka para
procesamiento y
análisis avanzado
en tiempo real.

Una infraestructura de nivel corporativo, provisionada, securizada y desplegada en la nube en menos de 25 minutos.