


SEMANA 7 — BIG DATA

Apache Hive

Del almacenamiento distribuido
al análisis de datos

El terreno físico: Almacenamiento y distribución en HDFS


Durante las semanas anteriores, HDFS resolvió un problema fundamental: el almacenamiento distribuido.



El abismo entre el dato y la respuesta

¿Cómo podemos analizar los millones de registros que hemos almacenado en HDFS?

HDFS no proporciona una interfaz declarativa. No puede responder por sí mismo:



La aparición de Apache Hive

Una capa de abstracción de alto nivel.

2007



Explosión de datos (Facebook).
Analistas conocen SQL, pero el
ecosistema Hadoop es complejo.

La barrera de MapReduce



Escribir trabajos distribuidos era
excesivamente complejo para
consultas analíticas.

Innovación



Hive permite utilizar una sintaxis
similar a SQL para trabajar con
grandes volúmenes de datos en
Hadoop.


HiveQL: El puente declarativo

El usuario indica qué resultado quiere obtener, y Hive determina cómo ejecutarlo en la infraestructura.

Programación Imperativa



Sintaxis Declarativa (HiveQL)




Sintaxis fuertemente inspirada en SQL:

- SELECT
- WHERE
- GROUP BY
- SUM(), COUNT()

Disminuye radicalmente la barrera de entrada al análisis masivo.


La gran distinción: Hive no reemplaza a HDFS

Uno de los errores más frecuentes es pensar: "Antes los archivos estaban en HDFS y ahora los guardamos en Hive."



Del archivo a la tabla: Proyectando una estructura

Una tabla en Hive no es un Excel gigante que contiene datos copiados. Es una estructura lógica que proporciona instrucciones sobre cómo interpretar un archivo de texto subyacente al momento de ser consultado.




Dos paradigmas de interpretación de datos

Base de Datos Relacional: Schema-on-Write



La estructura se define antes de insertar la información.

Apache Hive: Schema-on-Read




Los datos se almacenan crudos en HDFS primero; la estructura lógica se aplica dinámicamente en la consulta. Aporta máxima flexibilidad.

Tablas Internas vs. Tablas Externas


¿Qué sucede al eliminar una tabla?

Managed Tables



Hive controla el ciclo de vida completo.
Eliminar la tabla borra los datos físicos.


External Tables



Los datos existen de forma independiente.
Eliminar la definición lógica mantiene intacta
la información en HDFS.

Optimizando la estructura lógica

Hive no solo lee texto plano. Organiza los datos para evitar procesar información innecesaria:




Organizan físicamente los datos reduciendo la cantidad de registros a examinar.

Permiten lecturas analíticas mucho más eficientes al leer solo las columnas necesarias.

El regreso de los metadatos: Hive Metastore

Para poder proyectar su estructura, Hive necesita recordar información sobre los datos (columnas, tipos, ubicaciones, particiones).



HDFS: El almacenamiento físico (los libros en las estanterías).




Hive Metastore: El catálogo indispensable que comprende y localiza la información.

Diagnóstico de Metadatos: NameNode frente a Metastore



NameNode (Metadatos de HDFS)

- ✓ Archivos y directorios
- ✓ Bloques de datos
- ✓ Ubicaciones físicas en DataNodes
- ✓ Propiedades del sistema de archivos




Hive Metastore (Metadatos lógicos)

- ✓ Bases de datos y tablas
- ✓ Nombres de columnas y tipos de datos
- ✓ Particiones y formatos
- ✓ Ubicación lógica asociada

El pipeline de ejecución: ¿Qué ocurre al ejecutar una consulta?

El usuario no programa manualmente las operaciones distribuidas. Hive actúa como traductor: transforma consultas declarativas complejas en planes de ejecución eficientes.



Hive frente a una Base de Datos Relacional

Hive no fue diseñado para respuestas en milisegundos (OLTP). Es una herramienta analítica masiva (OLAP).



Feature	Relational DB	Hive
Orientación	Transaccional (OLTP)	Analítica por lotes (OLAP)
Latencia	Muy baja (milisegundos)	Históricamente mayor
Esquema	Schema-on-write	Schema-on-read
Uso Típico	Aplicaciones web, actualizaciones	Data warehouse, analítica masiva, ETL

HDFS

La nueva frontera conceptual

HDFS nos permitió aprender a almacenar datos distribuidos. Hive nos permitirá comenzar a hacer preguntas sobre esos datos.

