

Apache Spark: procesamiento distribuido de datos

De HDFS a Spark SQL en el
ecosistema Big Data



Spark en el ecosistema Big Data




¿Qué es Spark y por qué surge?


MapReduce: Cuello de botella en disco




Apache Spark: Diseñado para reutilizar



Arquitectura Spark: Desarmando el motor



Ejecución distribuida: Del código a la máquina



¡Atención!
Separar la jerarquía lógica
de la infraestructura física

Partición $\neq$ Worker


Las particiones son divisiones de datos,
los workers son máquinas físicas

Bloque HDFS $\neq$ Partición Spark

Almacenamiento vs Procesamiento en memoria

RDD: Resilient Distributed Dataset

La anatomía de la estructura fundamental de procesamiento en Spark.



Lazy Evaluation: Planificar antes de construir

Fase 1 Las Transformaciones

Construyen el plan lógico (DAG).
Spark solo toma nota.



Fase 2 El Gatillo

`count()` / `collect()` / `sum()`

Las **Acciones** solicitan
un resultado y encienden
el sistema.

Fase 3 La Ejecución

Spark dispara el Job, optimiza el DAG
y los Executors comienzan a trabajar.



Spark + HDFS: Procesando el dato inerte




HDFS almacena el dato inerte de forma distribuida.

Spark inyecta procesamiento en memoria a las particiones.

De RDD a DataFrame

Spark ahora entiende QUÉ significan tus datos, no solo dónde están.

Inyección de Schema



RDD: Colección distribuida de objetos abstractos.

DataFrame = RDD + Schema
(Filas y Columnas estructuradas).

DataFrame y Schema: Tipificando los datos

Un Schema define los nombres de columna y sus tipos de datos subyacentes.

DataFrame



<Integer>



<String>



<Double>

id_venta

ciudad

monto

V008

Valencia

2100.50

V009

Sevilla

450.00

V010

Madrid

1250.75



inferSchema

Spark lee una muestra de los datos para adivinar el tipo. Lento, pero automático. Ideal para exploración.




Schema Explícito

El programador dicta la estructura de antemano. Rápido, estricto y seguro. El estándar para producción.

Procesamiento con DataFrames: Flujo Analítico

De datos crudos a insights, sin código extenso.



Spark SQL: Consultas sobre DataFrames




¡ADVERTENCIA CRÍTICA!


Una Vista Temporal **NO** es una tabla física en HDFS ni en Hive. Vive puramente en la **memoria** y muere irremediabilmente cuando se cierra la sesión de Spark.

DataFrame API vs Spark SQL

No importa cómo lo escribas, Spark lo procesa exactamente igual.



HDFS + Hive + Spark: La Integración Real



Síntesis del Ecosistema y Comprobación



¿Qué gatilla la ejecución de un Job en Spark?

Una **ACCIÓN** (ej. count, collect). Las transformaciones son perezosas.

¿Qué diferencia un Worker de un Executor?

El **Worker** es el nodo físico de hardware; el **Executor** es el proceso lógico que corre las Tasks.

¿Un DataFrame altera el archivo HDFS original?

NO. Las estructuras en Spark son inmutables por diseño.